

## Методическая разработка для проведения лекции

### Занятие 8. Классификация образов с помощью функций правдоподобия

Учебные вопросы занятия:

1. Классификация образов как задача теории статистических решений
2. Байесовский классификатор в случае образов, характеризующихся нормальным распределением

Заключительная часть

#### Введение

Одной из важнейших задач информационной безопасности является задача распознавания образов, будь то обнаружение атаки, идентификация нарушителя, определение вида уязвимости и т.д. Острота решаемой проблемы заключается в том, что приходится решать следующие задачи:

- при огромнейших объемах обрабатываемой информации и постоянном дефиците сил и средств сохранять свою полную работоспособность. Следовательно, необходимо внедрение автоматизации процессов приема и обработки;
- постоянно обеспечивать признаковую доступность к объектам и источникам информации.

Очевидно, что эти задачи относятся к задачам распознавания образов и принятия решений. В силу огромнейших объемов обрабатываемой информации и требований к системе по обработке данной информации в реальном масштабе времени решить данные задачи ручными методами невозможно.


Для автоматизации решения задач такого типа необходим математический аппарат при описании происходящих процессов и процедур принятия решения. Этим занимается теория распознавания образов. Следовательно, для обеспечения работоспособности какого-либо устройства, подсистемы или системы в целом необходимо изучить элементы математического анализа и теории распознавания образов.

#### **1. Классификация образов как задача теории статистических решений**

С позиций системного подхода для изучения систем классифицирования (расознавания) необходимо сформулировать цель распознавания как такового и определить место распознавателя в технологическом процессе приема и обработки информации.

Целью функционирования любой системы распознавания является отнесение анализируемого образа к какой-либо группе объектов (классу) в соответствии с выбранной системой признаков.

Место устройств распознавания в структуре автоматизированного комплекса показано на рисунке.



Поскольку в рамках любого конкретного исследования все используемые термины и понятия должны быть точно и четко определены, введем основные определения, связанные с классифицированием.

*Класс* – множество объектов (предметов, явлений), объединенных некоторыми общими свойствами.

*Объект* является представлением своего класса.

*Признак* – общее свойство, объединяющее объекты в классы. Признаками могут быть только те свойства объектов, численные значения которых можно измерить.

*Образ* – совокупность значений признаков, характеризующих объект, и дающих его описание.

Так как прием и обработка информации осуществляются в условиях наличия различного рода случайных воздействий, то измеренные значения признаков – случайные величины. В зависимости от них реализацию образа относят к одному из заданных классов по выбранным правилам принятия решения. При этом обычно принятие решения производится сравнением реализации сигнала с эталонами классов.

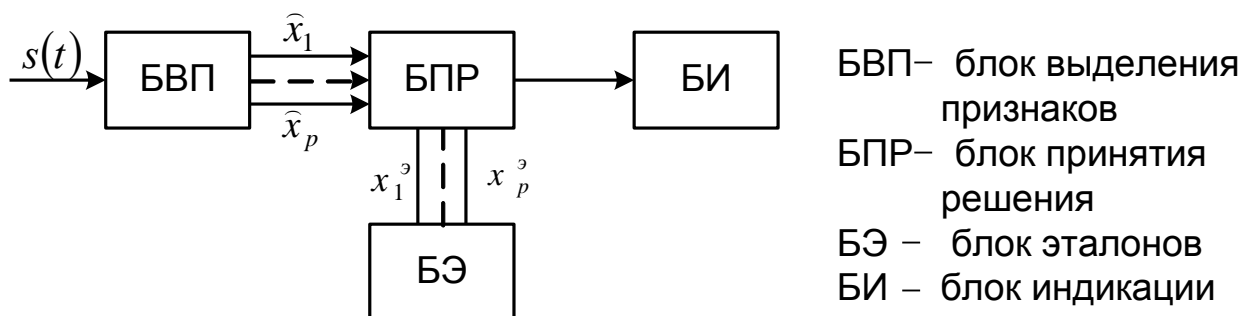
*Эталон* – типичный представитель класса или образец с усредненными значениями параметров.

На основании введенных определений задачи системы распознавания можно представить в следующем виде:

- разбиение множества элементов на классы  $\{A_i\}$ ;
- выбор пространства признаков распознавания  $A_i \Rightarrow P_i = \{p_k\}$ ;
- обучение системы распознавания (изменение эталона и признакового пространства, создание новых классов);
- разработка методов и алгоритмов распознавания (измерение порогов, выбор решающего правила);

– оценка эффективности системы распознавания в различных условиях ее функционирования (степень достижения цели функционирования системой распознавания).

Исходя из поставленных задач и преследуемой цели следует определить модель системы распознавания и представить ее в виде структурной схемы.



При распознавании воздействий на ПЭВМ или сервер первоначально выделяются (измеряются) признаки, которыми могут быть различные характеристики (параметры) воздействий и их сочетания. Принятая реализация воздействия поступает в блок выделения признаков (БВП), где измеряются его параметры. Оценки этих параметров сравниваются в блоке принятия решения (БПР) с эталонными значениями признаков, поступающими из блока эталонов (БЭ). Регистрация и отображение принятого решения производится в блоке индикации (БИ).

Рассмотрим основные виды методов распознавания: детерминистские, статистические, логические и синтаксические (лингвистические). Наибольшее внимание будет сосредоточено на статистических методах, поскольку они в наилучшей степени учитывают условия обеспечения информационной безопасности.

Математическое описание наиболее важных элементов этой модели базируется на принципах статистического описания различных образов и классификационных правилах, являющихся *оптимальными* в том смысле, что их использование обеспечивает в среднем наименьший риск от принятия неправильного решения о классификации.

Оптимальному качеству классификации со статистической точки зрения соответствует байесовский классификатор. Алгоритм его действия определяется выражением для математического ожидания потерь, обусловленных отнесением описания к некоторому классу  $j$ .

Выражение для средних потерь, возникающих при отнесении образа к классу  $j$ , сводится к следующему уравнению:

$$R_j(x) = \sum_{i=1}^M L_{ij} \omega(x/A_i) P(A_i),$$

где  $L_{ij}$  – величина потерь, связанных с отнесением образа  $x$  к классу  $j$ , когда в действительности он принадлежит классу  $i$ ;

$\omega(x/A_i)$  – плотность распределения вероятностей признака  $x$ .

В теории статистических решений величину  $R_j(x)$  часто называют *условными средними потерями*.

При распознавании каждого образа его можно отнести к одному из  $M$  возможных классов. Если для каждого образа  $X$  вычисляются значения условных средних потерь  $R_1(x), R_2(x), \dots, R_M(x)$ , и классификатор причисляет его к классу, которому соответствуют наименьшие условные потери, то очевидно, что и математическое ожидание полных потерь на множестве всех решений будет минимизировано. Классификатор, минимизирующий математическое ожидание общих потерь, называется байесовским классификатором.

Если  $M = 2$ , то при выборе класса 1 средние потери для предъявленного образа  $X$  составляют

$$R_1(x) = L_{11} \omega(x/A_1)P(A_1) + L_{21} \omega(x/A_2)P(A_2),$$

а для класса 2 –

$$R_2(x) = L_{12} \omega(x/A_1)P(A_1) + L_{22} \omega(x/A_2)P(A_2).$$

Как уже отмечалось, байесовский классификатор обеспечивает отнесение образа  $X$  к классу  $A_i$  с наименьшим значением средних потерь  $R_j$ , значит, образ  $X$  зачисляется в класс  $A_1$ , если выполняется условие  $R_1(x) < R_2(x)$ .

Подставив в данное неравенство значения условных средних потерь, получим

$$\begin{aligned} L_{11} \omega(x/A_1)P(A_1) + L_{21} \omega(x/A_2)P(A_2) < \\ < L_{12} \omega(x/A_1)P(A_1) + L_{22} \omega(x/A_2)P(A_2) \end{aligned}$$

или

$$(L_{21} - L_{22})\omega(x/A_2)P(A_2) < (L_{12} - L_{11})\omega(x/A_1)P(A_1),$$

$$\frac{\omega(x/A_1)}{\omega(x/A_2)} > \frac{(L_{21} - L_{22})P(A_2)}{(L_{12} - L_{11})P(A_1)}.$$

Выполнение этого условия определяет отнесение образа  $X$  к классу  $A_1$ . Левую часть неравенства называют *отношением правдоподобия* (оно является отношением двух функций правдоподобия). Величину

$$\Theta_{12} = \frac{(L_{21} - L_{22})P(A_2)}{(L_{12} - L_{11})P(A_1)}$$

часто называют *пороговым значением*.

В большинстве задач распознавания образов потери равны нулю (отсутствие потерь) при принятии правильного решения и единице – неправильного. Это соотношение устанавливает нормированную величину потерь, равную единице при неправильной классификации, и отсутствие потерь в случае правильной классификации образа. Поэтому функцию потерь можно представить следующим выражением:

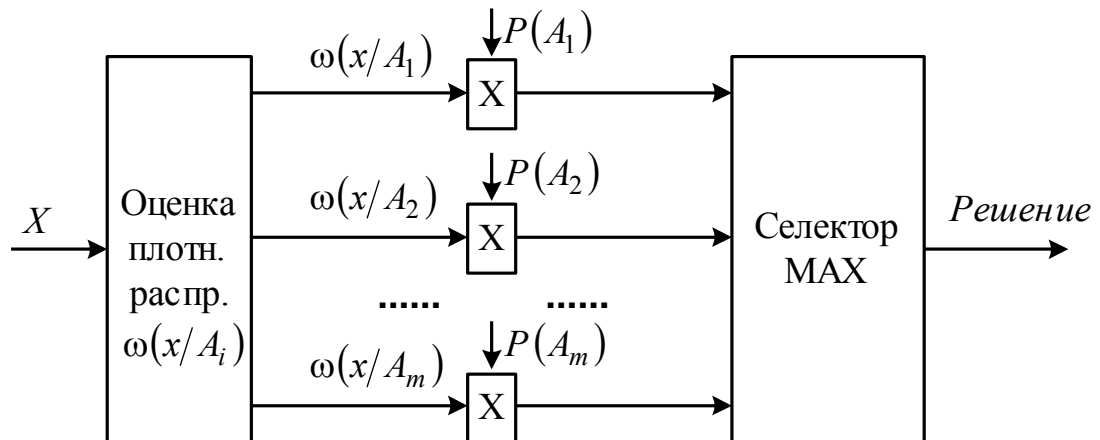
$$L_{ij} = 1 - \delta_{ij},$$

где  $\delta_{ij}$  – число Кронекера;  $\delta_{ij} = 1$  при  $i=j$ ,  $\delta_{ij} = 0$  при  $i \neq j$ .

Отсюда следует, что байесовский классификатор обеспечивает отнесение образа  $X$  к классу  $A_i$ , если выполняется условие

$$\omega(x/A_i)P(A_i) > \omega(x/A_j)P(A_j), \quad j=1, 2, \dots, M, \quad i \neq j.$$

Приведенные рассуждения позволяют на основе этого выражения реализовать схему распознавания, изображенную на рисунке.



Выводы:

Оптимальным с точки зрения нормирования потерь является байесовский классификатор.

Синтез байесовского классификатора требует знания априорных вероятностей и плотностей распределения для каждого класса образов, а в общем случае и стоимостей принятия решений.

## 2. Байесовский классификатор в случае образов, характеризующихся нормальным законом распределения

Одномерная плотность нормального распределения одной случайной величины  $x$  может быть представлена следующим выражением:

$$\omega(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2} \frac{(x-m)^2}{\sigma^2}}$$

Основными параметрами указанного закона распределения являются среднее значение  $m$  и дисперсия  $\sigma^2$ , поэтому часто его представляют в виде функции  $N(m, \sigma^2)$ . Эти параметры, в свою очередь, определяются следующим образом:

$$m = M[x] = \int_{-\infty}^{\infty} x \omega(x) dx,$$

$$\sigma^2 = M[(x-m)^2] = \int_{-\infty}^{\infty} (x-m)^2 \omega(x) dx.$$

Образы, характеризующиеся нормальным распределением, проявляют тенденцию к группировке вокруг среднего значения, а их рассеяние – пропорционально среднеквадратическому отклонению  $\sigma$ . Около 95 % объектов, извлеченных из совокупности с нормальным распределением, попадут в интервал, равный  $2\sigma$  и имеющий в качестве центра среднее значение  $m$ .

Рассмотрим  $M$  классов образов. Элементы этих классов описываются  $p$ -мерными случайными величинами  $x_1, x_2, \dots, x_p$ . Совокупность  $p$  случайных ве-

личин будем обозначать вектором или матрицей-столбцом  $x = \begin{bmatrix} x_1 \\ x_2 \\ \dots \\ x_p \end{bmatrix}$ . Будем рас-

сматривать случайные величины, которые имеют в каждом классе  $p$ -мерную нормальную плотность распределения:

$$\omega(x / A_i) = \frac{1}{(2\pi)^{p/2} |C_i|^{1/2}} e^{-\frac{1}{2} (x-m_i)^T C_i^{-1} (x-m_i)},$$

где  $i=1, 2, \dots, M$ ;

$|C_i|$  – определитель ковариационной матрицы  $C_i$ ;

$(x - m_i)^T$  – транспонированная матрица  $(x - m_i)$ .

Каждая условная плотность распределения полностью определена вектором средних значений  $m_i$  и ковариационной матрицей  $C_i$ , заданных соответственно:

$$m_i = M_i[x],$$

$$C_{jk}^i = \text{cov}(x_j, x_k) = M[(x_j - m_j^i)(x_k - m_k^i)],$$

где  $i=1, 2, \dots, M$  – номер класса;

$j, k=1, \dots, p$  – номер случайной величины;

$$C_i = M_i[(x - m)(x - m)^T],$$

где  $M_i$  обозначает оператор математического ожидания, определенный на образцах класса  $A_i$ :

$$C_i = \begin{bmatrix} c_{11}^i & c_{12}^i & \dots & c_{1p}^i \\ c_{21}^i & c_{22}^i & \dots & c_{2p}^i \\ \dots & & & \\ c_{p1}^i & c_{p2}^i & \dots & c_{pp}^i \end{bmatrix}.$$

Ковариационная матрица  $C_i$  является симметрической и положительно полуопределенной. Ее диагональный элемент  $c_{kk}$  есть дисперсия  $k$ -го элемента вектора образов. Элемент  $c_{jk}$ , не стоящий на диагонали матрицы, представляет собой ковариацию случайных переменных  $x_j$  и  $x_k$  (ковариация – смешанный момент второго порядка  $\text{cov}(x_i, x_j)$ ). Если переменные  $x_j$  и  $x_k$  независимы, то элемент  $c_{jk} = 0$ . Многомерная плотность нормального распределения сводится к произведению одномерных плотностей нормальных распределений, если все недиагональные элементы ковариационной матрицы равны нулю.

Отношение правдоподобия нормально распределенных случайных величин можно представить выражением

$$\frac{\omega(x/A_i)}{\omega(x/A_j)} = e^{-\frac{1}{2}[(x-m_i)^T C_i^{-1}(x-m_i) - (x-m_j)^T C_j^{-1}(x-m_j)]}.$$

Так как ковариационная матрица симметрическая, данное отношение сводится к следующему выражению:

$$\frac{\omega(x/A_i)}{\omega(x/A_j)} = e^{x^T C_i^{-1}(m_i - m_j) - \frac{1}{2}(m_i - m_j)^T C_j^{-1}(m_i - m_j)}.$$

Введем функцию

$$u_{ij}(x) = \ln \left( \frac{\omega(x/A_i)}{\omega(x/A_j)} \right).$$

Тогда для разделяющей функции получаем

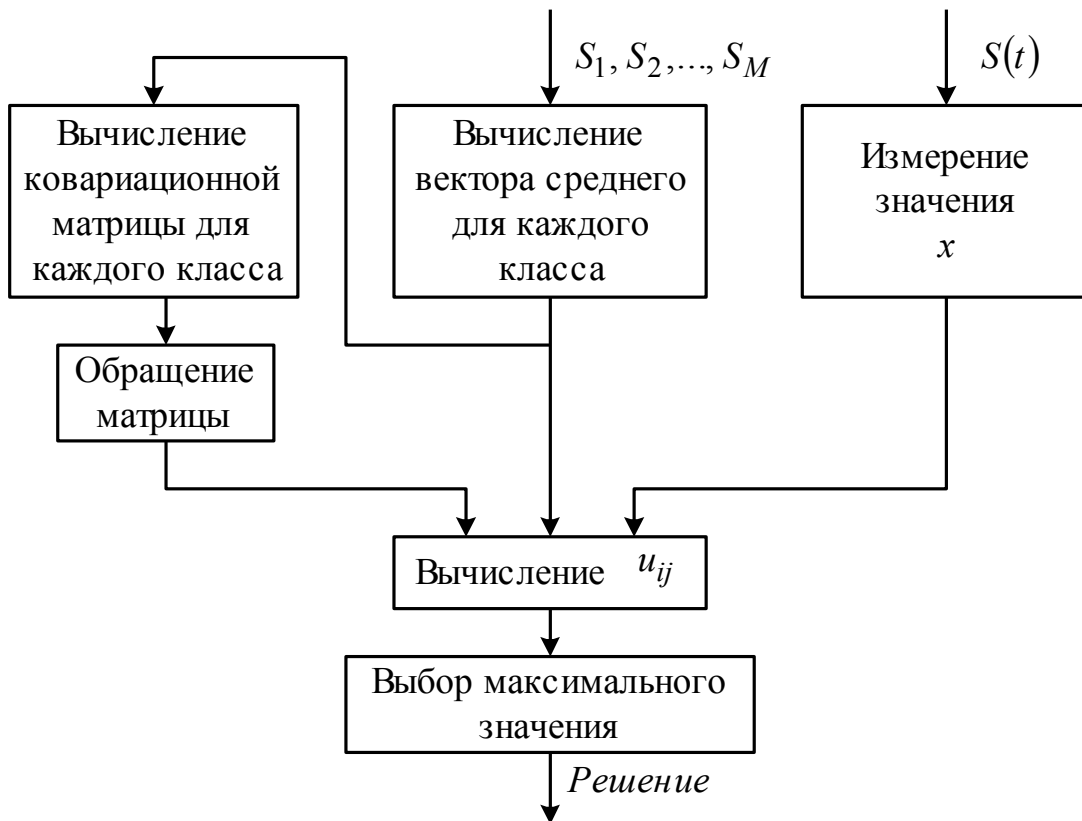
$$u_{ij}(x) = x^T C_i^{-1} (m_i - m_j) - \frac{1}{2} (m_i + m_j)^T C_j^{-1} (m_i - m_j).$$

Для определения оптимальной разделяющей функции требуется вычислить  $M(M-1)$  значений функции  $u_{ij}(x)$  для всех  $i, j: i \neq j$  и выбрать наибольшее из полученных значений. Если окажется, что этот максимум равен  $u_{kj}$ , то относим  $x$  к классу  $A_k$ . Схема оптимального распознавания, воспроизводящая описанный метод, представлена на рисунке.

Следующее уравнение описывает гиперплоскость, проведенную в  $n$ -мерном гиперпространстве и разделяющую его в случае наличия двух классов на две части:

$$u_{ij}(x) = x^T C_i^{-1} (m_i - m_j) - \frac{1}{2} (m_i + m_j)^T C_j^{-1} (m_i - m_j) = 0.$$

Решающее правило можно представить в общем виде:





$$\begin{aligned} u_{ij} &> 0 \quad \text{для} \quad X \in A_i, \\ u_{ij} &< 0 \quad \text{для} \quad X \in A_j. \end{aligned}$$

Вектор средних значений определяют в соответствии со следующим выражением (равенство приближенное, так как значение рассчитывается по экспериментальным данным):

$$m = M[x] \approx \frac{1}{N} \sum_{j=1}^N x_j,$$

где  $N$  – объем выборки.

Элементы ковариационной матрицы  $C$  задаются следующим образом:

$$c_{lk} = M[(x_l - m_l)(x_k - m_k)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x_l - m_l)(x_k - m_k) \omega(x_l, x_k) dx_l dx_k$$

или в векторной форме

$$C = M[(x - m)(x - m)^T] = M[xx^T - 2xm^T - mm^T] = M[xx^T] - mm^T.$$

Так как логарифм отношения правдоподобия  $u_{ij}$  является линейной комбинацией компонентов образа  $x$ , подчиняющихся нормальному распределению, то  $u_{ij}$  также описывается нормальным распределением. Поэтому математическое ожидание логарифма отношения правдоподобия для класса  $\omega_i$  в случае равных ковариационных матриц можно представить в виде

$$M[u_{ij}] = m_i^T C^{-1}(m_i - m_j) - \frac{1}{2}(m_i + m_j)^T C^{-1}(m_i - m_j)$$

Обозначим математическое ожидание разделяющей функции через  $r_{ij}$ :

$$M[u_{ij}] = \frac{1}{2} r_{ij}.$$

Величину  $r_{ij}$  часто называют *расстоянием Махаланобиса* между плотностями распределений  $\omega(x/A_i)$  и  $\omega(x/A_j)$ . Если  $C$  – единичная матрица, то расстояние Махаланобиса представляет собой квадрат расстояния между средними значениями величин  $\omega(x/A_i)$  и  $\omega(x/A_j)$ :

$$[u_{ij}] = M[(u_{ij} - \bar{u}_{ij})^2] = r_{ij}.$$

Вероятность ошибки при распознавании зависит от расстояния Махаланобиса между классами, которое выражается следующим образом:

$$r_{ij} = (m_i - m_j)^T C^{-1}(m_i - m_j),$$

где  $m_i$  и  $m_j$  – соответственно векторы средних для каждого класса;

$C^{-1}$  – матрица, обратная ковариационной.

Зависимость вероятности ошибки от  $r_{ij}$  можно записать в виде выражения

$$P_{\text{ош}} = \Phi\left(-\frac{1}{2}\sqrt{r_{ij}}\right) + \left(1 - \Phi\left(\frac{1}{2}\sqrt{r_{ij}}\right)\right),$$

где  $\Phi$  – интеграл вероятности.


График зависимости вероятности ошибки классификации от величины расстояния Махаланобиса представлен на рисунке.

Выводы:

Огромные объемы обрабатываемой информации, состояние собственных сил и средств делает задачу распознавания одной из самой важной задачей обеспечения информационной безопасности.

Актуальность решения этой задачи определяется тем, что проблемы связанные с распознаванием образов в полном объеме не решены.

Существуют математические методы, реализация которых позволяет подойти к решению поставленной задачи. Оптимальным с точки зрения нормирования потерь является байесовский классификатор.



В случае многомерной случайной величины необходимо определение оптимальной разделяющей функции. Эта процедура трудоемкая, но разработаны оптимальные схемы распознавателей, и при введении некоторых допущений эти схемы технически реализуемы. Оптимальным с точки зрения нормирования потерь является байесовский классификатор.

Вероятность ошибки при распознавании зависит от расстояния Махаланобиса между классами.

**Заключительная часть.**

Подвожу итоги занятия.

**Рекомендованная литература:**

1. Хемминг Р.В. Численные методы. – М.: Наука, 1972.
2. Левин Б.Р. Теоретические основы статистической радиотехники. – М.: Сов. радио и связь, 1974.
3. Ту Дж., Гонсалес Р. Принципы распознавания образов. – М.: Мир, 1978.
4. Горелик А.Л., Скрипкин В.А. Методы распознавания. – М.: Высшая школа, 1989.
5. Фомин Я.А., Тарловский Г.Р. Статистическая теория распознавания образов. – М.: Радио и связь, 1986.