

Практическая работа №5: Методы статистического анализа

Цель работы:

1. Изучить основные методы статистического анализа данных.
2. Научиться применять методы оценки параметров случайных величин.

Теоретическая часть

Основные этапы статистического анализа данных

1. *Определение эмпирических вероятностных характеристик:*

- вычисление математического ожидания, дисперсии, корреляционного момента, вероятностей событий и функции распределения вероятностей.
- установление свойств распределения (симметрия, нормальность и т.д.).

2. *Построение гистограммы вероятностей:*

- восстановление эмпирического распределения случайной последовательности.
- выдвижение гипотезы о виде распределения.

3. *Проверка гипотезы:*

- использование критериев согласия для проверки соответствия эмпирических и аналитических характеристик.

4. *Оценка параметров случайных величин:*

- точечные оценки: определение значения параметра.
- интервальные оценки: нахождение доверительного интервала.

Основные понятия

1. *Состоятельность оценки:* Оценка сходится к истинному значению параметра при увеличении объема выборки.
2. *Несмещенность оценки:* Среднее значение оценки равно истинному значению параметра.
3. *Эффективность оценки:* Оценка имеет минимальную дисперсию среди всех возможных оценок.

Формулы для оценки параметров

1. Математическое ожидание:

$$\widehat{M}(x) = \frac{1}{n} \sum_{i=1}^n x_i$$

где x_i — элементы выборки, n — объем выборки.

2. Дисперсия:

$$\widehat{D}(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \widehat{M}(x))^2$$

3. Корреляционный момент:

$$R_{xy} = \frac{1}{n} \sum_{i=1}^n (x_i - \widehat{M}(x))(y_i - \widehat{M}(y))$$

4. Коэффициент корреляции:

$$r_{xy} = \frac{R_{xy}}{\sigma_x \cdot \sigma_y}$$

Типовое задание

Провести статистический анализ выборки данных.

Условие: Дана выборка данных:

$$X = [12, 15, 14, 10, 13, 15, 14, 16, 12, 11]$$

1. Найти математическое ожидание, дисперсию и среднеквадратическое отклонение.
2. Построить гистограмму распределения.
3. Проверить гипотезу о нормальности распределения с помощью критерия согласия (критерий Шапиро-Уилка).
4. Найти доверительный интервал для математического ожидания с уровнем доверия 95%.

Решение

Теоретический разбор

1. *Математическое ожидание* ($M(x)$) — это среднее значение выборки. Оно показывает, где сосредоточены данные.
2. *Дисперсия* ($D(x)$) — мера разброса данных относительно среднего значения.
3. *Среднеквадратическое отклонение* ($\sigma(x)$) — корень квадратный из дисперсии.
4. *Гистограмма* — графическое представление распределения данных.
5. *Критерий Шапиро-Уилка* — статистический тест для проверки гипотезы о нормальности распределения.
6. *Доверительный интервал* — интервал, в который с заданной вероятностью попадает истинное значение параметра.

Программная реализация

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy.stats import shapiro, norm
4 X = [12, 15, 14, 10, 13, 15, 14, 16, 12, 11]
5 # 1. Математическое ожидание, дисперсия и среднеквадратическое отклонение
6 mean_x = np.mean(X)
7 variance_x = np.var(X, ddof=1) # Дисперсия с исправлением на n-1
8 std_dev_x = np.std(X, ddof=1) # Среднеквадратическое отклонение
9 print(f"Математическое ожидание: {mean_x}")
10 print(f"Дисперсия: {variance_x}")
11 print(f"Среднеквадратическое отклонение: {std_dev_x}")
12 # 2. Построение гистограммы
13 plt.hist(X, bins=5, edgecolor='black', alpha=0.7)
14 plt.title("Гистограмма распределения")
15 plt.xlabel("Значения")
16 plt.ylabel("Частота")
17 plt.show()
18 # 3. Проверка гипотезы о нормальности
19 stat, p_value = shapiro(X)
20 print(f"Статистика Шапиро-Уилка: {stat}, p-value: {p_value}")
21 if p_value > 0.05:
22     print("Гипотеза о нормальности не отвергается (распределение нормальное).")
23 else:
24     print("Гипотеза о нормальности отвергается (распределение не нормальное).")
25 # 4. Доверительный интервал для математического ожидания
26 confidence = 0.95
27 n = len(X)
28 alpha = 1 - confidence
29 t_critical = norm.ppf(1 - alpha/2) # Критическое значение t
30 margin_of_error = t_critical * (std_dev_x / np.sqrt(n))
31 lower_bound = mean_x - margin_of_error
32 upper_bound = mean_x + margin_of_error
33 print(f"Доверительный интервал для математического ожидания: [{lower_bound:.2f}, {upper_bound:.2f}"]")
```

Задания для самостоятельного выполнения

1. Дана выборка данных:

$$Y = [20, 22, 19, 21, 20, 23, 22, 21, 20, 19]$$

Найдите математическое ожидание, дисперсию и среднеквадратическое отклонение.

2. Постройте гистограмму для выборки:

$$Z = [5, 7, 8, 6, 5, 7, 8, 9, 6, 5]$$

Определите, является ли распределение нормальным (используйте критерий Шапиро-Уилка).

3. Для выборки:

$$W = [3, 4, 5, 6, 7, 8, 9, 10, 11, 12]$$

Найдите доверительный интервал для математического ожидания с уровнем доверия 99%.

4. Даны две выборки:

$$A = [10, 12, 14, 16, 18, 20]$$

$$B = [5, 6, 7, 8, 9, 10]$$

Найдите корреляционный момент и коэффициент корреляции.

5. Для выборки:

$$V = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]$$

Найдите объем выборки, необходимый для оценки математического ожидания с погрешностью 0.5 и доверительной вероятностью 95%.

Тест

1. Что такое математическое ожидание случайной величины?

- А) Среднее значение выборки.
- В) Мера разброса данных.
- С) Вероятность события.
- Д) Коэффициент корреляции.

2. Какой из критериев используется для проверки нормальности распределения?

- A) Критерий Шапиро-Уилка.
 - B) Критерий Стьюдента.
 - C) Критерий Фишера.
 - D) Критерий хи-квадрат.
3. Что показывает дисперсия случайной величины?
- A) Среднее значение.
 - B) Мера разброса данных.
 - C) Вероятность события.
 - D) Коэффициент корреляции.
4. Какой из параметров не относится к нормальному распределению?
- A) Математическое ожидание.
 - B) Дисперсия.
 - C) Коэффициент корреляции.
 - D) Медиана.
5. Что такое доверительный интервал?
- A) Интервал, в который с заданной вероятностью попадает истинное значение параметра.
 - B) Среднее значение выборки.
 - C) Мера разброса данных.
 - D) Вероятность события.
6. Какой из методов используется для оценки параметров случайной величины?
- A) Метод Монте-Карло.
 - B) Метод наименьших квадратов.
 - C) Метод максимального правдоподобия.
 - D) Все вышеперечисленные.
7. Что такое коэффициент корреляции?
- A) Мера зависимости между двумя случайными величинами.
 - B) Среднее значение выборки.
 - C) Вероятность события.
 - D) Мера разброса данных.

8. Какой из параметров определяет форму нормального распределения?

- A) Математическое ожидание.
- B) Дисперсия.
- C) Среднеквадратическое отклонение.
- D) Все вышеперечисленные.

9. Какой объем выборки необходим для оценки вероятности события с погрешностью 0.05 и доверительной вероятностью 95%?

- A) 100.
- B) 400.
- C) 20.
- D) 200.

10. Что такое ковариационная матрица?

- A) Матрица, содержащая дисперсии и ковариации случайных величин.
- B) Матрица, содержащая только дисперсии случайных величин.
- C) Матрица, содержащая только средние значения случайных величин.
- D) Матрица, содержащая только корреляции случайных величин.