

Задание 1. ОЧИСТКА ДАННЫХ

Изучаемые понятия: парциальная обработка, аппроксимация, максимальное правдоподобие, аномалии, шумы, вейвлет-преобразование.

Данные – это отдельные факты, характеризующие объекты, процессы и явления предметной области, а также их свойства. Данные для анализа должны быть представительными, точными и достоверными. Однако они, как правило, поступают из разных источников и не всегда соответствуют требуемым критериям качества. Они могут содержать опечатки и орфографические ошибки, фиктивные и логически неверные значения, нарушать уникальность, стандарты на формат записи и т.п. Некачественные данные могут привести к неправильным результатам анализа.

К сожалению, Deductor Studio не имеет механизмов ввода и ручной правки данных и не все ошибки могут быть выявлены на начальной стадии. Тем не менее, предварительная обработка данных – необходимый шаг для обеспечения удовлетворительного результата анализа. Чем тщательнее подготовлены данные для анализа, тем в дальнейшем будет меньше проблем.

Предварительная обработка включает в себя очистку данных – набор методов повышения качества данных. К очистке данных относят заполнение пропусков, редактирование аномалий и ошибок, сглаживание данных, обнаружение дубликатов и противоречий и др.

Кроме очистки, могут потребоваться предварительные преобразования данных – например, снижение их размерности, устранение незначущих факторов и др.

В Deductor для решения задач очистки данных предназначен обработчик Парциальная обработка. Он включает несколько шагов. Каждое поле анализируемого набора обрабатывается независимо от остальных полей.

Заполнение пропусков (данные неизвестны либо их забыли внести и т.п.) должно быть первым шагом предварительной обработки данных. Для заполнения обработчик Парциальная обработка предлагает два способа: Аппроксимация и Максимальное правдоподобие.

Аппроксимация заполняет пропущенное значение, усредняя соседние. Используется только для упорядоченных данных. Максимальное правдоподобие подставляет значение, наиболее вероятное со статистической точки зрения. Рекомендуется использовать этот метод для неупорядоченных данных.

Редактирование аномалий. Аномалии (аномальные значения) – случайные либо редко происходящие события, которые не укладываются в общую картину процесса (резкие отклонения). Обработчик Парциальная обработка может отредактировать аномальные значения с разной степенью их подавления – малой, средней, большой.

Очистка от шумов. Шумы в данных обычно представляют собой быстрые случайные изменения значений. Шумы могут скрывать общую тенденцию, затрудняют построение модели прогноза.

Сглаживание данных необходимо, если ряд данных оказывается неравномерным, содержит большое количество мелких структур, что затрудняет поиск общих закономерностей.

Обработчик Парциальная обработка предлагает три механизма сглаживания и вычитания шума. Вариант Сглаживание позволяет указать величину полосы пропускаемых частот (т.е. отсекается все, что выше этого порога). Чем больше требуется сгладить данные, тем меньше должно быть значение полосы. Однако слишком узкая полоса может привести к потере полезной информации.

Вариант Вычитание шума может быть использован, если шум имеет нормальное распределение с малой дисперсией. Deductor позволяет задать степень вычитания шума: малую, среднюю и большую.

Сглаживание с помощью вейвлет-преобразования потребует задать глубину разложения и порядок вейвлета. Глубина разложения определяет масштаб отсеиваемых деталей. При увеличении глубины разложения модель отбрасывает шум все большего уровня. Однако слишком большие значения глубины разложения приводят к потере полезной информации. Порядок вейвлета определяет гладкость обработанного ряда данных: чем больше значение параметра, тем больше сглаживаются выбросы.

Дубликаты и противоречия в данных можно обнаружить с помощью обработчика Deductor Дубликаты и противоречия.

Практическая работа.

Очистка данных

Создайте папку Очистка данных для сохранения всех файлов практической работы. Запустите Deductor, сохраните новый проект в этой папке в файле. Регулярно сохраняйте результаты работы.

Задание 1. Восстановление пропущенных данных.

Порядок выполнения работы:

1. Подготовьте в Excel таблицу значений функции $\sin(x)$, где аргумент x изменяется от 0 до 10 с шагом 0,05.
2. Удалите несколько значений функции (не аргумента), так чтобы были пропущенные данные.
3. Сохраните полученную таблицу в текстовом формате в Вашей папке.
4. Загрузите эти данные в Deductor. Назовите ветвь Восстановление значений $\sin(x)$. Задайте отображение представлений Таблица и Диаграмма.
5. В открывшемся окне выберите пункт Парциальная обработка (в разделе Очистка данных). На втором ее шаге выберите переключатель Аппроксимация. На последующих шагах не задавайте никакой обработки данных. Отобразите представления Таблица и Диаграмма.
6. Сравните обработанные данные с необработанными.

COL_X	Sin(x)
0	0
0,05	0,049979169
0,1	0,099833417
0,15	0,149438132
0,2	0,198669331
0,25	0,247403959
0,3	0,295520207
0,35	0,343632941857143
0,4	0,389418342
0,45	0,434965534
0,5	0,479425539
0,55	0,522687229
0,6	0,564642473
0,65	0,605186406
0,7	0,644217687
0,75	0,68163876
0,8	0,717356091
0,85	0,751280405
0,9	0,78332691
0,95	0,816216605863137
1	0,841470985
1,05	0,867423226
1,1	0,89120736
1,15	0,91276394
1,2	0,932039086
1,25	0,950662714672656
1,3	0,963558185
1,35	0,975723358
1,4	0,98544973

Рисунок 1 — Excel таблица значений функции $\sin(x)$

COL_X	Sin(x)
0	0
0,05	0,049979169
0,1	0,099833417
0,15	0,149438132
0,2	0,198669331
0,25	0,247403959
0,3	0,295520207
0,35	
0,4	0,389418342
0,45	0,434965534
0,5	0,479425539
0,55	0,522687229
0,6	0,564642473
0,65	0,605186406
0,7	0,644217687
0,75	0,68163876
0,8	0,717356091
0,85	0,751280405
0,9	0,78332691
0,95	
1	0,841470985
1,05	0,867423226
1,1	0,89120736
1,15	0,91276394
1,2	0,932039086
1,25	
1,3	0,963558185
1,35	0,975723358
1,4	0,98544973

Рисунок 2 — Excel таблица значений функции $\sin(x)$ после удаления значений




Рисунок 3 — Отображение данных до и после аппроксимации

Задание 2. Редактирование аномалий.

Порядок выполнения работы:

1. Скопируйте в свою папку демонстрационный файл Anketa.txt. Загрузите его данные в тот же проект с помощью Мастера импорта. Назовите ветвь Редактирование аномалий Anketa. Отобразите таблицу и точечную диаграмму для поля Сумма кредита.

2. Для созданной ветви проведите Парциальную обработку. При этом:

- в ее окне Восстановление пропущенных данных установите переключатель Отключить;

- в окне Редактирование аномальных значений выберите поле Количество, установите флажок Редактирование аномальных значений, в списке Степень подавления выберите пункт Малая.

- Сглаживание не задавайте. Выполните редактирование аномалий, нажав кнопки Пуск и Далее. Отобразите снова таблицу и точечную диаграмму для поля Сумма кредита.

3. Сравните обработанные и необработанные данные. Выведите в правой нижней части окна панель детализации. Выясните с ее помощью, на какие значения были заменены аномальные.

4. Для той же ветви Редактирование аномалий Anketa проведите еще одно редактирование аномалий, выбрав большую степень их подавления. Дайте узлам сценария понятные названия. Сравните новые величины для аномальных значений. Сделайте выводы.




Рисунок 4 — Диаграмма «Сумма кредита»




Рисунок 5 — Окно редактирования «Малая»




Рисунок 6 — Обработанная диаграмма «Сумма кредита»

Мастер обработки - Парциальная обработка (3 из 7)

Парциальная предобработка
Редактирование аномальных значений

Имя столбца: COL5
Тип данных: Вещественный

☒ Редактирование аномальных значений
Используется алгоритм робастной фильтрации

Степень подавления: Средняя

Степень подавления определяет допустимую величину отклонения от нормы (робастной оценки).

< Назад Далее > Отмена

Рисунок 7 — Окно редактирования «Средняя»




Рисунок 8 — Обработанная диаграмма «Сумма кредита»






Рисунок 9 — Результаты редактирование аномалий

Задание 3. Сглаживание и очистка от шумов.

1. Скопируйте в свою папку демонстрационный файл dynamics_website.txt. В том же проекте создайте еще одну ветвь сценария Сглаживание шумов website, импортировав данные этого файла. Отобразите при этом диаграмму (линии).

2. Проведите для этого узла трижды сглаживание и очистку от шумов всеми тремя способами (по очереди), которые предлагает обработчик Парциальная обработка (шаг Спектральная обработка). Для каждого из преобразований отобразите диаграмму (линии). Укажите настройки преобразований:

- для опции Сглаживание оставьте величину полосы пропускания равной 50;
- для Вычитания шума установите среднюю степень вычитания;
- для Вейвлет-преобразования оставьте значения глубины 3 и порядка 6.
- Дайте полученным трем узлам сценария осмысленные названия.
- Сравните с помощью диаграмм исходные данные и полученные после каждого из преобразований. Сделайте выводы.




Рисунок 10 — Диаграмма шумов




Рисунок 11 — Полоса пропускания 50




Рисунок 12 — Диаграмма первого преобразования




Рисунок 13 — Средняя степень вычитая шума




Рисунок 14 — Диаграмма второго преобразования




Рисунок 15 — Вейвлет преобразование




Рисунок 16 — Диаграмма третьего преобразования

Задание для самостоятельной работы.

1. Скопируйте в свою папку демонстрационный файл Trade.txt. Загрузите в тот же проект данные файла. Назовите ветвь Очистка данных trade. Отобразите диаграмму (линии).

2. Проведите парциальную обработку данных, применив к узлу сразу в один прием все три типа обработки: аппроксимацию данных, подавление аномалий большой степени и сглаживание данных с полосой пропускa 50. Отобразите диаграмму (линии). Сравните исходные и преобразованные данные.

3. Измените полученный узел. Замените сглаживание данных на вейвлет-преобразование с глубиной разложения 2 и порядком вейвлета 6. Сравните результаты. Сохраните файл проекта.




Рисунок 17 — Исходные данные




Рисунок 18 — Три типа обработки в один прием




Рисунок 19 — Результативные данные

The screenshot shows a software window titled 'Мастер обработки - Парциальная обработка (4 из 7)'. Inside, there's a section for 'Парциальная предобработка' with a sub-option 'Спектральная обработка'. A list on the left shows 'Дата (Год + Месяц)' and 'Количество'. On the right, settings for 'Имя столбца' (COL2) and 'Тип данных' (Вещественный) are shown. Under 'Спектральная обработка', four options are listed: 'Отключить', 'Сглаживание данных', 'Вычитание шума', and 'Вейвлет преобразование' (which is selected). For the selected option, 'Полоса пропускания' is 50, 'Степень вычитания шума' is 'Малая', 'Глубина разложения' is 2, and 'Порядок вейвлета' is 6. Navigation buttons at the bottom are '< Назад', 'Далее >', and 'Отмена'.

Рисунок 20 — Настройка глубины разложения и порядка вейвлета




Рисунок 21 — Диаграмма результативных данных

Вопросы для самоконтроля

1. Каково назначение предварительной обработки данных?

— Предварительная обработка данных — это этап подготовки данных к анализу и построению моделей, цель которого — повысить качество данных, устранить проблемы, которые могут исказить результаты анализа или обучения моделей. Она включает очистку, преобразование, восстановление пропусков, удаление шума и аномалий, приведение данных к единому формату. Без качественной предобработки даже лучшие алгоритмы дают низкое качество.

2. Каково назначение обработчика Дубликаты и противоречия?

— Обработчик «Дубликаты и противоречия» в Deductor предназначен для: Поиска и удаления/объединения полных дубликатов строк.

Обнаружения и разрешения функциональных дубликатов (строки с одинаковыми значениями по ключевым полям).

Выявления противоречивых записей (те же ключи, но разные значения в других полях) и их исправления (выбор наиболее частотного значения, среднего, последнего по времени и т.д.).

Это особенно важно при интеграции данных из разных источников.

3. В чем отличия предварительной обработки и очистки данных?

Какие разделы обычно включает очистка данных?

— Очистка данных — это часть предварительной обработки, сосредоточенная на устранении «грязных» данных.

Предварительная обработка шире: включает очистку + преобразования (нормализация, кодирование категориальных признаков, генерация новых признаков, дискретизация, балансировка классов и т.д.).

Очистка данных обычно включает следующие разделы:

- Удаление/восстановление пропущенных значений
- Удаление дубликатов и разрешение противоречий
- Обработка выбросов и аномалий
- Устранение шума
- Исправление синтаксических ошибок (опечатки, разные написания одного и того же и т.д.)
- Приведение типов данных и форматов

4. Для чего предназначен обработчик Deductor Парциальная обработка?

— Обработчик «Парциальная обработка» позволяет применять операции предобработки только к части строк данных, соответствующим заданному фильтру (условию). Это нужно, когда:

- разные группы записей требуют разных правил обработки (например, для клиентов из разных регионов — разные способы заполнения пропусков),
- нужно обработать только аномальные или проблемные записи, оставив остальные без изменений,
- проводится поэтапная сложная очистка с разными условиями.

5. Для чего необходимо восстанавливать пропущенные данные? Какие способы заполнения пропусков предлагает Deductor? Для каких данных подходит каждый из них?

— Восстановление пропусков необходимо, потому что большинство алгоритмов не работают с NULL-значениями, а простое удаление строк с пропусками может привести к сильной потере данных.

Deductor предлагает следующие способы:

- Константа — подходит, когда пропуски означают осознанное отсутствие (например, «0» или «не указано»).
- Среднее/медиана/мода — для числовых (среднее/медиана) и категориальных (мода) признаков с случайными пропусками.
- Значение из предыдущей/следующей строки — для временных рядов (интерполяция по времени).
- Линейная интерполяция — для упорядоченных данных (временные ряды).
- KNN (метод ближайших соседей) — универсальный, хорошо работает, когда есть зависимости между признаками.
- Регрессионное восстановление — когда можно предсказать пропущенное значение по другим признакам.
- ЕМ-алгоритм и множественное заполнение — для сложных случаев с высокой долей пропусков.

6. Какие данные считаются зашумленными? Какие варианты сглаживания и вычитания шума предлагает Deductor?

— Зашумлённые данные содержат случайные ошибки или отклонения, не несущие полезной информации (например, ошибки измерений, опечатки).

Deductor предлагает:

- Скользящее среднее (moving average)
- Экспоненциальное сглаживание
- Фильтр Ходрика-Прескотта
- Сплайн-сглаживание
- Вейвлет-фильтрация (удаление высокочастотного шума)
- Биннинг (группировка в интервалы и замена средним/медианой по корзине)
- Регрессионное сглаживание

7. Что такое аномалии и как они могут повлиять на результат анализа данных? Каким образом можно отредактировать аномальные значения в Deductor?

— Аномалии (выбросы) — это значения, существенно отличающиеся от большинства наблюдений. Они могут быть: реальными (например, мошенническая транзакция), ошибочными (ошибка ввода).

Влияние: сильно искажают средние, дисперсию, корреляции, могут полностью «сломать» модель (особенно линейные и деревья решений чувствительны).

В Deductor обработка аномалий:

- Визуализация (диаграмма размаха, гистограммы)
- Автоматическое обнаружение:
 - по правилу 3σ (три сигма)
 - по межквартильному размаху (IQR): $Q1 - 1,5 \times IQR$ и $Q3 + 1,5 \times IQR$
 - по процентилем
- Действия с найденными аномалиями:
 - удаление строк
 - замена на среднее/медиану/граничное значение (winsorization)
 - замена на значение, предсказанное моделью
 - ручная правка через таблицу

Задание 2. КЛАСТЕРИЗАЦИЯ ДАННЫХ

Изучаемые понятия: кластер, кластеризация, интерпретация, профили кластеров, поддержка кластера, мощность кластера, значимость поля, топографическая диаграмма, диаграмма размещения.

Группировка объектов по различным признакам (критериям) способствует более успешному их анализу. Если классы объектов заранее известны, используют классификацию. Однако может оказаться значительное число объектов, которые не попадают в заготовленные классы или относятся к ним лишь частично. В этих случаях может использоваться кластеризация (от англ. cluster (скопление) – кластер, группа объектов с общими признаками).

Кластеризация – это разбиение объектов на группы так, чтобы объекты внутри кластера были максимально похожи друг на друга и максимально отличались от объектов из других кластеров. Чем больше похожи объекты внутри кластера и чем больше отличий между кластерами, тем точнее кластеризация.

Кластеризация (= сегментирование, группировка) может выступать этапом анализа данных. При этом выделяют группы схожих объектов, изучают их особенности и для каждой группы строят отдельную модель. Так, в маркетинге можно выделить группы клиентов, покупателей, товаров, исходя не из общих соображений, а для данной конкретной ситуации, и разработать для каждой из них отдельную стратегию.

Обычно при кластеризации количество кластеров неизвестно и сложно выбрать меру «похожести» объектов. В связи с этим существует огромное число алгоритмов кластеризации. Однако это не все сложности данного метода. Сформированным группам объектов (кластерам) надо дать содержательную интерпретацию – только тогда можно рассчитывать на успешный анализ данных.

Для интерпретации результатов кластеризации надо исследовать каждый полученный кластер, его статистические характеристики, распределение значений каждого признака (параметра) в кластере, оценить мощность кластера (поддержку кластера) – число объектов, попавших в него.

Среди обработчиков Deductor Studio имеется инструмент Кластеризация. Он позволяет кластеризовать данные двумя способами:

- а) указав заранее количество групп (кластеров),
- б) разрешив определить количество кластеров автоматически.

Важно помнить, что оба метода предполагают наличие в исходных данных некоторых отдельных групп, сгустков объектов – иначе найденные кластеры будут малоинформативны.

Результаты группировки можно отобразить с помощью таблицы Профили кластеров. Она позволяет упорядочить данные в соответствии с поддержкой кластеров. Можно отсортировать данные по значимости полей данных – степени зависимости результата от данного поля. Значимость данных отображается в числовом и графическом виде. Кроме того, можно вывести статистические характеристики – средние значения, доверительный интервал, стандартные ошибку и отклонение и т.п.

Удобна для анализа многомерная диаграмма, с помощью которой можно отобразить в пространстве значения параметров для каждого кластера. Эта диаграмма допускает свободное вращение.

Одна из разновидностей многомерной диаграммы – топографическая диаграмма, которая использует цвет для отображения исследуемого параметра.

Диаграмма размещения позволяет отобразить больше данных, чем многомерная, – по сравнению с ней можно добавить еще три параметра, придав точкам диаграммы разные форму, цвет и размер.

Практическая работа.

Кластеризация данных

Задание. Кластеризация с помощью одноименного обработчика Deductor.

Требуется распределить регионы на кластеры по демографическим данным.

Порядок выполнения работы:

1. Создайте папку Кластеризация. Скопируйте в нее и импортируйте в Deductor данные из демонстрационного файла Population.txt. Сохраните проект в файле.

2. Проведите редактирование аномалий и удаление шумов для полей Удельный вес городского населения, Изменение численности населения, Среднегодовая численность населения занятых в экономике, Среднедушевой денежный доход.

3. Выберите Мастер обработки Кластеризация.

4. На втором шаге Мастера укажите поля Численность населения и Регион информационными столбцами, а 4 обработанных (сглаженных) поля – входными.

5. На следующем шаге определите все множество данных как обучающее.

6. Далее задайте фиксированное количество кластеров, равное пяти.

7. Выберите из списка визуализаторов способы отображения данных Профили кластеров и Куб.

8. Для настройки визуализатора Куб выберите рассматриваемые свойства как факты, а номер кластера и регион – как измерения. Затем укажите отображение среднего значения по всем фактам рассматриваемой группы.

9. Проанализируйте полученные результаты:

- Рассмотрите таблицу Профили кластеров. Задайте сортировку кластеров по убыванию поддержки (количества записей, попавших в кластер). Поля упорядочьте по убыванию значимости (степени зависимости результата от данного поля) для столбца

Итого (т.е. для всех данных).

Для каждого поля отобразите только три параметра – Значимость, Доверительный интервал и Среднее значение поля. Определите кластеры, где самым значимым параметром является среднедушевой доход (определите его среднюю величину). Проанализируйте другие значимые параметры для этих кластеров. Выясните, какие регионы попали в эти кластеры, отобразив данные по кластеру.

Найдите кластеры регионов с положительным и отрицательным значимым приростом населения. Выясните другие значимые их характеристики.

- Добавьте визуализатор Многомерная диаграмма: задайте для него отображение регионов, номеров кластеров и (по очереди) какого-либо из исследуемых параметров – например, среднедушевого дохода и т.д. Отобразите легенду.

- Возможно, более удобным для анализа может оказаться визуализатор Диаграмма размещения – он позволяет вывести больше параметров за счет вариаций цвета, размера и формы точек диаграммы.

- Используйте для анализа данных вкладку Куб, выведя на ней кросс-диаграмму.

10. Проведите для тех же исходных данных кластеризацию на 4 кластера. Отобразите необходимые визуализаторы и проведите аналогичный анализ получившихся кластеров.

11. Выберите тот вариант кластеризации, который допускает более удачную интерпретацию. Переименуйте для него каждый кластер в зависимости от его особенностей.

12. Скопируйте узел удачной (на Ваш взгляд) кластеризации и переместите его непосредственно к импортированным данным (без их сглаживания). Проведите эту кластеризацию на несглаженных данных и сравните результаты группировки в обоих случаях.

Сохраните файл проекта.

Таблица					
3 / 72					
Субъект	Численность	Удельный вес городского населения	Изменение численности	Среднегодовая численность занятых	Среднедушевой доход
Москва	13010112	98,7	0,4	11000000	54000
Московская область	8524665	77,5	0,3	4700000	43000
Краснодарский край	5838273	57,2	-0,1	3300000	38000
Санкт-Петербург	5601911	100	0,2	5000000	52000
Свердловская область	4222695	86,3	0	2000000	39000
Ростовская область	4152518	68,4	-0,2	1800000	35000
Республика Башкортостан	4046094	62,5	0,2	2200000	34000
Республика Татарстан	3902781	76	0,3	2000000	36000
Новосибирская область	2786540	75,3	0,1	1500000	35000
Челябинская область	3474110	75,8	-0,3	1600000	36000
Омская область	1805806	72,1	-0,4	800000	32000
Республика Дагестан	3259890	60,5	0,6	1500000	30000
Красноярский край	2837374	75	0	1300000	37000
Ставропольский край	2738369	59,9	0,3	1200000	33000
Самарская область	3313795	64,2	0,1	1500000	36000
Волгоградская область	2434046	79,4	-0,2	1200000	34000
Саратовская область	2289678	58,3	-0,3	900000	32000
Республика Ингушетия	534491	52,4	0,8	250000	28000
Тюменская область	1502656	75	0,2	900000	38000
Республика Крым	1909499	50,2	-0,1	850000	33000
Ленинградская область	2059479	65,4	0	1300000	35000
Приморский край	1922813	72	0,1	1000000	34000
Ханты-Мансийский автономный округ	1615938	90,1	1,5	1400000	50000
Белгородская область	1540486	67,8	0,2	700000	33000
Чеченская Республика	1514603	50,5	1,3	600000	28000
Удмуртская Республика	1448922	70	-0,1	700000	32000
Тульская область	151214	77	0	60000	33000
Владимирская область	1297936	80,3	-0,2	600000	34000

Рисунок 22 — Исходные данные




Рисунок 23 — Редактирование аномалий и удаление шумов

Субъект	Численность	Удельный вес городского населения	Изменение численности	Среднегодовая численность занятых	Среднедушевой до
Москва	13010112	73,434811014396	-0,00367887156830446	6268420,39802322	38947,57488
Московская область	8524665	69,0161070348325	0,0230087667462608	7073205,17266194	39365,9380
Краснодарский край	5838273	68,4768830969777	0,041847533179243	7545714,82242277	39530,0563
Санкт-Петербург	5601911	73,4500200889129	0,0516374076290824	7611644,54755484	39427,5651
Свердловская область	4222695	68,8758372771623	0,0521643653006464	7263862,60879271	39066,6910
Ростовская область	4152518	68,605900157152	0,0442103364468578	6561550,35632821	38475,7676
Республика Башкортостан	4046094	73,4576337972164	0,0294617144522329	5613880,14979792	37700,9984
Республика Татарстан	3902781	68,7389917603233	0,0103258367149046	4553469,40673469	36802,6530
Новосибирская область	2786540	68,7389917603233	-0,0103258367149046	3507474,27991109	35850,0288
Челябинская область	3474110	73,4576337972164	-0,0294617144522329	2574292,99964732	34915,6222
Омская область	1805806	68,605900157152	-0,0442103364468578	1811497,2717221	34069,0265
Республика Дагестан	3259890	68,8758372771623	-0,0521643653006464	1236657,41632997	33371,1006
Красноярский край	2837374	73,4500200889129	-0,0516374076290824	838528,331323606	32868,9247
Ставропольский край	2738369	68,4768830969777	-0,041847533179243	593011,900988261	32591,9891
Самарская область	3313795	69,0161070348325	-0,0230087667462608	477371,892293204	32549,9461
Волгоградская область	2434046	73,434811014396	0,00367887156830446	477570,56167219	32732,1126
Саратовская область	2289678	68,352251393199	0,0361399475307496	586739,050680642	33108,7496
Республика Ингушетия	534491	69,1594631112016	0,0716238116463228	796512,531670052	33633,9837
Тюменская область	1502656	73,4120432136585	0,106974346850564	1085904,14205076	34250,0878
Республика Крым	1909499	68,2323052945067	0,138942154724413	1413498,78226863	34892,7171
Ленинградская область	2059479	69,3055601489251	0,164507763338537	1717616,93031335	35496,6161
Приморский край	1922813	73,3817715363265	0,181183303121229	1926124,83704851	36001,275
Ханты-Мансийский автономный округ	1615938	68,1173337615587	0,187262245426977	1973806,45153493	36356,0349
Белгородская область	1540486	69,4540461874424	0,181992015283589	1822015,38720528	36524,1771
Чеченская Республика	1514603	73,3440689095222	0,1656520489017	1473870,01041565	36485,6796
Удмуртская Республика	1448922	68,007613770848	0,139529385104307	979133,13855869	36238,3984
Тульская область	151214	69,6045635108811	0,105794197429676	425920,922522245	35797,6263

Рисунок 24 — Редактированные данные




Рисунок 25 — Мастер обработки «Кластеризация»




Рисунок 26— Выбор информационных и входных столбцов

Мастер обработки - Кластеризация (3 из 7)

Разбиение исходного набора данных на подмножества
 Настройте разбиение исходного множества данных на обучающее и тестовое множества

Способ разделения исходного множества данных: Случайно

Столбец для разделения исходного множества:

Множество	Размер		Порядок сортировки
	В процентах	В строках	
☒ Обучающее	100,00	72	По возрастанию
☒ Тестовое	0,00	0	По возрастанию
ИТОГО:	100,00	72	

Количество строк (всего): 72

< Назад Далее > Отмена

Рисунок 27 — Выбор всего множества как обучающее

Мастер обработки - Кластеризация (4 из 7)

Настройка параметров кластеризации
 Укажите параметры кластеризации

☐ Автоматически определить количество кластеров (g-means)

Уровень значимости, %:

Чем больше уровень значимости, тем больше кластеров будет сгенерировано при кластеризации.

☒ Фиксированное количество кластеров (k-means)

Количество кластеров: 5

Каждая строка исходного набора данных будет отнесена к одному из кластеру, количество которых определяется выше.

< Назад Далее > Отмена

Рисунок 28 — Фиксированное кол-во кластеров




Рисунок 29 — Способ отражения данных «Профили кластеров» и «Куб»




Рисунок 30 — Выбор рассматриваемых свойств как факт




Рисунок 31 — Отображение среднего значения по всем фактам




Рисунок 32 — Таблица «Профили кластеров»




Рисунок 33 — Настройка сортировки




Рисунок 34 — Отображение трех параметров




Рисунок 35 — Кластеры со значимым параметром «Среднедушевой доход»

Субъект	Удельный вес городского населения	Изменение численности	Среднегодовая численность занятых	Среднедушевой
Омская область	68,605900157152	-0,0442103364468578	1811497,2717221	34069
Республика Дагестан	68,8758372771623	-0,0521643653006464	1236657,41632997	33371
Ставропольский край	68,4768830969777	-0,041847533179243	593011,900988261	32591
Самарская область	69,0161070348325	-0,0230087667462608	477371,892293204	32549
Саратовская область	68,352251393199	0,0361399475307496	586739,050680642	33108
Республика Ингушетия	69,1594631112016	0,0716238116463228	796512,531670052	33633
Хабаровский край	67,9034096474428	0,0272440703427453	-439110,299091573	34470
Пензенская область	69,7567495098251	-0,0110266760740458	-589323,356168722	33678
Ярославская область	67,8049724282034	-0,0705408792992973	-263077,344846837	32100
Брянская область	67,7125392570131	-0,0921153058003856	712004,596300571	3041
Липецкая область	67,6263328134775	-0,0426179288902145	666367,127816606	30019
Калмыкия	67,5465607764698	0,0134648399061485	240362,473761614	30524
Карачаево-Черкесская Республика	67,4734153238145	0,0100225851102879	547273,493248919	31078
Республика Коми	67,4070726693136	-0,0621087368359561	767558,062278167	31133
Республика Марий Эл	67,347692638233	-0,145752690023466	408438,10001788	3084
Оренбургская область	67,2954182822684	-0,1653613608593	330609,324226875	30782
Республика Саха (Якутия)	67,2503755349222	-0,0917235273559628	417433,790855578	31308
Смоленская область	67,2126729081179	0,031567714295804	-7881,20830614725	32176

Рисунок 36 — Данные регионов по кластеру 4

Субъект	Удельный вес городского населения	Изменение численности	Среднегодовая численность занятых	Среднедушевой
Челябинская область	73,4576337972164	-0,0294617144522329	2574292,99964732	34915
Красноярский край	73,4500200889129	-0,0516374076290824	838528,331323606	32868
Волгоградская область	73,434811014396	0,00367887156830446	477570,56167219	32732
Тюменская область	73,4120432136585	0,106974346850564	1085904,14205076	34250
Владимирская область	73,299026162176	0,067287749169723	-79438,6272606053	35194
Тверская область	73,2467518062114	-0,04446132420438	-517119,811247453	3287
Калининградская область	73,0478836679746	-0,0011380984189197	317858,938031523	30307
Камчатский край	72,9681116309669	0,0199049285100093	386143,054094159	30935
Кемеровская область	72,9819051874313	-0,0329339568264422	775145,97902512	31175
Сахалинская область	72,4771106828858	-0,0100621033371117	168477,9680764	31886
Тамбовская область	71,2888842955194	0,0693485158811558	-146814,077183227	32430
Томская область	72,3621391499377	0,100413220951456	-194411,092939313	32625
Чукотский автономный округ	71,4349813332428	0,134501619337224	69918,1143772691	32769
Ямало-Ненецкий автономный округ	72,2421930512454	0,135899815737539	333497,66944507	32704
Забайкальский край	71,5783374096119	0,110843784721531	802982,31829127	32335
Алтайский край	72,1175613474667	0,0884231815858074	880486,162334001	32069
Архангельская область	71,7186071672821	0,0379902895076387	632048,715687095	31510
Астраханская область	71,9805442872924	0,0160605165899357	389811,249491834	31274
Республика Алтай	71,8554526841211	-0,008716322495553	33922,2380542415	31011

Рисунок 37 — Данные регионов по кластеру 0

Субъект	Удельный вес городского населения	Изменение численности	Среднегодовая численность занятых	Среднедушее
Ульяновская область	69,9102375548731	-0,0875319188912269	90980,0802375488	31412
Чувашская Республика	73,1873717751308	-0,0946480468219972	445668,404204398	30844
Кировская область	70,0646578798806	-0,081135155616377	835248,591306672	30142
Вологодская область	73,12102912063	-0,0637489677704708	807608,303288961	30015
Кабардино-Балкарская Республика	70,219638472759	-0,0207407813551172	478607,447090436	30127
Калужская область	70,3748059716854	0,020924374793994	268474,269314219	30743
Республика Карелия	70,5297865645638	-0,00810883342154081	693529,800514069	3115
Курская область	70,6842068895713	-0,0927346289573519	678360,119146657	31049
Магаданская область	72,789472016241	-0,121650483240735	542588,919023201	30945
Мурманская область	70,8376949346193	-0,162311248216117	318784,160470536	30770
Новгородская область	72,6910347970016	-0,16924980925386	295261,41611279	30744
Орловская область	70,9898809335633	-0,150437687119921	392007,15879827	30891
Псковская область	72,5868306735964	-0,12529422098964	434165,142799847	31070
Рязанская область	71,140398257002	-0,0522753589080864	324346,886041674	31588

Рисунок 38 — Данные регионов по кластеру 1

Субъект	Удельный вес городского населения	Изменение численности	Среднегодовая численность занятых	Среднедушее
Москва	73,434811014396	-0,00367887156830446	6268420,39802322	38947
Московская область	69,0161070348325	0,0230087667462608	7073205,17266194	3936
Краснодарский край	68,4768830969777	0,041847533179243	7545714,82242277	39530
Санкт-Петербург	73,4500200889129	0,0516374076290824	7611644,54755484	39427
Свердловская область	68,8758372771623	0,0521643653006464	726362,60879271	39066
Ростовская область	68,605900157152	0,0442103364468578	6561550,35632821	38475
Республика Башкортостан	73,4576337972164	0,0294617144522329	5613880,14979792	37700
Республика Татарстан	68,7389917603233	0,0103258367149046	4553469,40673469	36802
Новосибирская область	68,7389917603233	-0,0103258367149046	3507474,27991109	35850

Рисунок 39 — Данные регионов по кластеру 2

Субъект	Удельный вес городского населения	Изменение численности	Среднегодовая численность занятых	Среднедушее
Республика Крым	68,2323052945067	0,138942154724413	1413498,78226863	34892
Ленинградская область	69,3055601489251	0,164507763338537	1717616,93031335	35496
Приморский край	73,3817715363265	0,181183303121229	1926124,83704851	3600
Ханты-Мансийский автономный округ	68,1173337615587	0,187262245426977	1973806,45153493	36356
Белгородская область	69,4540461874424	0,181992015283589	1822015,38720528	36524
Чеченская Республика	73,3440689095222	0,1656520489017	1473870,01041565	36485
Удмуртская Республика	68,007613770848	0,139529385104307	979133,13855869	36238
Тульская область	69,6045635108811	0,105794197429676	425920,922522245	35797

Рисунок 40 — Данные регионов по кластеру 3




Рисунок 41 — Кластер 3 с положительной численностью




Рисунок 42 — Кластер 2 с отрицательной численностью




Рисунок 43 — Визуализатор «Многомерная диаграмма»




Рисунок 44 — Настройки многомерной диаграммы




Рисунок 45 —Многомерная диаграмма

Настройка диаграммы размещения
 Настройка различных параметров диаграммы размещения

Доступные поля

- ... **Субъект**
- **Удельный вес городского населения**
- Изменение численности
- Среднегодовая численность занятых
- Среднедушевой доход
- ... Численность
- ... **Номер кластера**
- Расстояние до центра кластера

Ось X:
 ... Субъект

Ось Y:
 ... Номер кластера

Ось Z:
 — Удельный вес городского насе

Форма объекта:
 ... Субъект

Цвет объекта:
 ... Субъект

Размер объекта:
 ... Удельный вес городского насе

< Назад Далее > Отмена

Рисунок 46 — Настройки диаграммы размещения




Рисунок 47 — Диаграмма размещения

		Кластеры					Итого
		0	1	3	2		
Поля	Показатели	30 (41,7%)	22 (30,6%)	12 (16,7%)	8 (11,1%)		
9.0 Среднедушевой доход	Значимость	100,0%	92,3%	100,0%	99,9%	100,0%	
9.0 Удельный вес городского населения	Значимость	100,0%	100,0%	98,0%	100,0%	100,0%	
9.0 Среднегодовая численность занятых	Значимость	100,0%	94,4%	100,0%	98,8%	100,0%	
9.0 Изменение численности	Значимость	89,1%	75,1%	99,6%	93,3%	100,0%	

Рисунок 48 — Кластеризация на 4 кластера




Рисунок 49 — Диаграмма размещения для 4-х кластеров

Вывод: 4 кластера дают неясную картину происходящего, 5-й кластер имеет некоторые просадки, которые указывают на различия с остальными кластерами. Выбираем для дальнейшей работы 5-й кластер.

Кластер 0 — Кластер со средней/выше средней урбанизацией и существенным влиянием занятости

Кластер 1 — Кластер демографически нестабильных регионов (с сильными перепадами в доходах и изменении численности)

Кластер 2 — Наименьшее изменение численности, мегаполисы

Кластер 3 — Кластер безработных людей

Кластер 4 — Кластер с высокоурбанизированными регионами с высокой занятостью




Рисунок 50 — Узел удачной кластеризации




Рисунок 51 — Кластеризация на не сглаженных данных

Кластер сформировался совсем по-другому. Теперь можно охарактеризовать кластеры следующим образом:

Кластер 0 — Кластер с самым большим притоком денежных средств за счёт численности населения и его увеличения

Кластер 1 — Кластер с низким удельным весом городского населения

Кластер 2 — Кластер стабильно прогрессирующих регионов

Кластер 3 — Кластер безработных людей/с низкими доходами

Кластер 4 — Кластер с наименьшим изменением в численности населения

Вопросы для самоконтроля

1. Что такое кластер?

— Кластер — это группа объектов (наблюдений, записей в данных), которые имеют схожие характеристики между собой и в то же время существенно отличаются от объектов других групп. Проще говоря, это "естественная" группировка данных, выявленная алгоритмом на основе их сходства.

2. Чем кластеризация отличается от классификации?

— Кластеризация — это обучение без учителя. Алгоритм ищет скрытые структуры в данных, не зная заранее, какие группы существуют. Исходные данные не размечены.

Классификация — это обучение с учителем. Алгоритму заранее известны метки классов (например, "спам"/"не спам"), и он обучается на размеченных данных, чтобы относить новые объекты к одному из этих известных классов.

3. Как реализована кластеризация в программе Deductor?

— В Deductor кластеризация реализована с помощью алгоритма К-средних (K-Means). Его основная идея:

- 1) Пользователь задаёт число кластеров K .
- 2) Алгоритм случайно выбирает K точек в пространстве данных как начальные центроиды кластеров.
- 3) Каждый объект приписывается к ближайшему центроиду.
- 4) После приписывания всех объектов позиции центроидов пересчитываются как среднее значение всех объектов в кластере.
- 5) Шаги 3 и 4 повторяются до тех пор, пока центроиды не перестанут значительно смещаться или не будет достигнуто максимальное число итераций.

4. Каким образом может быть задано число кластеров при кластеризации в Deductor?

— Число кластеров в Deductor задаётся вручную пользователем перед запуском алгоритма. Для выбора оптимального числа кластеров можно использовать:

- Экспертное знание о предметной области.
- Анализ доли объяснённой дисперсии: запуск алгоритма с разным количеством кластеров и выбор такого K, при котором добавление нового кластера уже не даёт значительного улучшения качества группировки.

5. Что такое мощность кластера (поддержка), значимость полей? Как эти показатели могут быть использованы в интерпретации результатов кластеризации?

— Мощность кластера (поддержка) — это количество объектов, попавших в данный кластер. Позволяет оценить размер кластера. Большая мощность указывает на распространённость данного типа объектов в данных.

Значимость полей — это статистический показатель, который отражает, насколько сильно поле (переменная) влияет на формирование данного кластера по сравнению с другими кластерами. Высокая значимость поля означает, что среднее значение этого поля в кластере сильно отклоняется от общего среднего по всем данным.

Использование при интерпретации: Анализируя таблицу профилей, можно легко интерпретировать кластеры. Например: «Кластер 3 характеризуется значительно высокими значениями поля Средний чек и значительно низкими значениями поля Частота покупок». Это позволяет дать содержательное описание каждому сегменту.

6. Какие способы визуализации доступны для представления результатов кластеризации?

— Таблица профилей (Profiles Table), Многомерная диаграмма (Multidimensional Plot), Диаграмма размещения (Placement Diagram), Древовидная карта (Tree Map)

7. Как устроена таблица профилей, какие данные она позволяет отобразить?

— Таблица профилей — это основная таблица для интерпретации кластеров. Она состоит из строк (поля данных) и столбцов (кластеры + общая статистика). Для каждого поля в каждом кластере отображается:

- Среднее значение в кластере.
- Сравнение с общим средним. Столбец закрашивается синим, если значение ниже общего среднего, и красным, если выше.
- Значимость этого поля для кластера.

Эта таблица позволяет сразу увидеть, чем каждый кластер отличается от общего "портрета" данных.

8. Какие способы сортировки и фильтрации данных допускает таблица профилей?

— Сортировка: Можно сортировать строки (поля) по названию, значимости или по разнице средних для выбранного кластера. Это помогает быстро найти наиболее характерные признаки для конкретного сегмента.

Фильтрация: Можно отфильтровать поля, оставив только те, которые имеют статистически значимые отклонения от общего среднего (например, только те, где значимость выше определённого порога). Это упрощает анализ, убирая шумовые поля.

9. В чем отличие представления многомерной диаграммы в виде поверхности или топографической карты?

— Оба способа визуализируют трёхмерные данные на плоскости.

- Поверхность (Surface): Отображает данные как непрерывную «поверхность рельефа», где высота соответствует значению третьего показателя. Напоминает гладкий 3D-ландшафт.
- Топографическая карта (Topographic Map): Отображает этот же рельеф с помощью изолиний (линий равного значения), подобно географической карте. Это более строгий и точный способ, позволяющий точнее определить численное значение в любой точке, но он менее интуитивен для восприятия рельефа.

10. Какие дополнительные средства по сравнению с многомерной диаграммой использует диаграмма размещения для отображения большего числа параметров?

— Многомерная диаграмма обычно отображает 3-4 параметра (X, Y, Z и, возможно, цвет/размер точки). Диаграмма размещения расширяет возможности за счёт:

- Размера маркеров (точек), который может кодировать значение четвёртой переменной.
- Формы маркеров, которая может кодировать значение пятой переменной (например, разные геометрические фигуры для разных категорий).
- Цвета маркеров, который может кодировать шестую переменную (категориальную или непрерывную).
- Таким образом, диаграмма размещения позволяет одновременно отображать до 6 измерений данных.

Задание 3.

САМООРГАНИЗУЮЩИЕСЯ КАРТЫ КОХОНЕНА

Изучаемые понятия: карта Кохонена, ячейка карты Кохонена, матрица расстояний, обучение без учителя.

Самоорганизующиеся карты Кохонена (Kohonen Self-Organizing Map) применяются для отображения результатов кластеризации. Карты Кохонена позволяют отобразить многомерное пространство в двумерном.

Карта Кохонена состоит из прямоугольных или шестиугольных ячеек. Объекты, признаки которых близки, попадают в одну ячейку или в ячейки, расположенные вблизи. В общем случае в ячейку попадает несколько объектов.

Ячейки карты раскрашиваются в разные цвета (или оттенки серого цвета) в зависимости от значений параметров, соответствующих каждой ячейке. Для этого сначала выделяются диапазоны значений параметра. Каждому диапазону ставится в соответствие цвет (или оттенок серого), и ячейки карты «раскрашиваются» соответствующими цветами.

Количество карт равно количеству анализируемых параметров. Каждая карта соответствует одному параметру объекта (т.е. одному входному полю данных).

Можно отобразить в виде карты Матрицу расстояний, показывающую, насколько близко расположены друг к другу соседи по кластеру. Если используются оттенки серого цвета, то чем дальше соседи, тем светлее цвет узла.

Отличие самоорганизующихся карт Кохонена в том, что могут вовсе отсутствовать выходные поля в обучающей выборке. Поскольку самообучающиеся карты – это алгоритм обучения без учителя, то у них вообще нет выходных полей в том виде, как в задачах регрессии и классификации. Даже если задать выходные поля, они не будут участвовать в обучении нейросети, а только лишь в отображении карт. Собственно, указание выходных полей удобно использовать в картах Кохонена для поиска зависимостей.

В остальном нормализация полей и настройка обучающей выборки проводится так же, как и для нейросетей.

Число кластеров обычно выбирают в пределах от 4 до 9 – 2-3 кластера малоинформативны, а больше десятка кластеров трудно обрабатывать.

Следует помнить о том, что карты Кохонена не решают задачу кластеризации, а лишь предлагают гипотезы о кластерной структуре данных. Эти гипотезы могут оказаться ложными, поэтому их необходимо подтверждать другими методами.

Кроме того, обычно начальные значения построения карт Кохонена задаются случайными числами, так что если проводить обучение несколько раз, результаты могут быть непохожими.

Для каждого кластера необходимо провести его содержательную интерпретацию, понимая при этом, что любая кластеризация субъективна и не существует единого универсального алгоритма кластеризации.

Практическая работа.

Кластеризация с помощью карт Кохонена

Задание 1. Кластеризация банков.

Имеется база данных коммерческих банков с показателями деятельности за текущий период. Необходимо провести их кластеризацию, т.е. выделить однородные группы банков.

Порядок выполнения работы:

1. Создайте папку Карты Кохонена. Скопируйте в нее и импортируйте в Deductor данные из файла Banks.txt. Сохраните проект в файле.

2. Запустите Мастер обработки и выберите обработчик Карта Кохонена.

- На втором шаге Мастера укажите выходным столбцом поле Прибыль, а поля Филиалы, Сумма активов, Собственные активы, Банковские активы, Средства в банке – входными.

- Оставьте значения по умолчанию для обучающего и тестового множеств, настроек параметров карты Кохонена, за исключением числа кластеров: задайте фиксированное число кластеров 4.

3. После завершения процесса обучения в списке визуализаторов выберите Карту Кохонена и Что–если.

- В Мастере настройки карты Кохонена укажите поля для отображения: все входные и выходные столбцы и кластеры. Способ раскраски – цветная палитра. Задайте отображение границ кластеров.

4. На полученной карте Кластеры все данные будут отображены в виде четырех областей разного цвета.

- Выберите кластер меньшего размера. Проанализируйте аналогичные по расположению области других карт: выясните размеры различных активов для банков этого кластера. (Цветовая шкала числовых величин расположена под каждой картой: синие цвета соответствуют наименьшим значениям, красные оттенки – наибольшим.)

- Откройте панель данных внизу окна и включите фильтрацию по кластеру. Выясните, какие банки попали в рассматриваемый кластер.

- Затем выберите самый большой кластер и проанализируйте финансовые показатели его банков на остальных картах. Аналогично – для остальных кластеров.

5. Изучите распределение кластеров на одной из карт с финансовыми показателями – например, Сумма активов. Добавьте визуализатор Многомерная диаграмма для этого же показателя (оси: номер кластера, банк, сумма активов). Сравните оба вида визуализации.

6. С помощью карты Филиалы проверьте, что число филиалов не сказалось на результатах кластеризации.

- Добавьте визуализацию Профилей кластеров. Оставьте в этой таблице параметры Значимость, Доверительный интервал и Среднее. Проверьте значимость поля Филиалы для всех кластеров – соответствует ли она карте Кохонена?

7. С помощью карты Прибыль проверьте, имеется ли связь прибыльности банков и их группировки.

- Создайте еще один узел сценария – аналогичную Карту Кохонена для тех же данных, указав вместо входного параметра Филиалы входной параметр Прибыль. Дайте различные названия обоим узлам сценария.

- Визуализируйте таблицу Профили кластеров. Проверьте значимость поля Прибыль для разных кластеров.

- Сравните оба результата кластеризации на картах Кохонена. Сохраните файл проекта.

Номер	Банк	Рег. Номер	Реутеры	Филиалы	Город	Количество рабочих	Сумма активов	Собственные активы	Банковские активы	Депозиты физ. лиц	Деп. юр.
2	Внешторгбанк	1000	-	32	Москва	3297	101660298	23236327	84343558	2086142	349
3	Газпромбанк	354	GZPM	27	Москва	2559	79012789	9255041	74409960	3948269	357
4	ООО "Международный Промышленный банк"	2056	TIBP	4	Москва	459	77888642	26409116	58647197	157065	14
5	Международный Московский Банк	1	IMBX	1	Москва	621	63910966	1176462	62436148	1291941	426
6	ОАО "АЛЬФА-БАНК"	1326	ALFM	17	Москва	2323	57510886	12446938	52348562	4052929	125
7	ОАО "ПСБ"	439	ICSP	44	Санкт-Петербург	3579	49406525	1275859	17091603	1531605	92
8	Банк Москвы	2748	-	34	Москва	2810	31352124	3335734	30287158	2498692	223
9	АКБ "РОСБАНК" (ОАО)	2272	-	13	Москва	989	28105202	4691449	25807591	2583476	125
10	АКБ "ДИБ"	2783	DIBM	0	Москва	377	27350369	2616993	26986210	1231564	190
11	КБ "Сиббанк Т/О"	2557	-	1	Москва	210	26240408	2063168	23291673	327804	81
12	ОАО МАКБ "Возрождение"	1439	VOZM	62	Москва	3439	25446423	1520076	9879932	968729	25
13	ОАО РИКБ "Башкредитбанк"	2275	BKRE	4	Уфа	1838	23304860	2833897	21190313	713888	101
14	ЗАО Банк "МЕНАТЕП СПб"	3279	MTSP	48	Санкт-Петербург	2145	19541965	2268343	9479194	1210206	104
15	БНП-Дрезднер Банк	2455	NDMO	1	Санкт-Петербург	185	17689833	84312	13082069	232842	27
16	АВТОбАНК	30	-	25	Москва	2732	17229288	1530584	15502811	1673414	34
17	ОАО Банк "Петрокоммерц"	1776	PCBM	13	Москва	1006	16690301	727690	10372701	1092558	63
18	АКБ "НРБАНК"	2170	NRB/B	0	Москва	320	15791359	5075844	15773889	228337	35
19	АКБ "Еврофинанс"	2402	EFIN	1	Москва	298	15191022	2835944	13398039	1496066	32
20	ООО Райффайзенбанк Австрия	3292	RZBM	0	Москва	212	14892329	593460	11685822	865363	17
21	КБ "ГЮТА-БАНК"	1623	GUTA	33	Москва	1906	14799899	2008471	12398573	567578	56
22	ГЛОБЭКСБАНК	1942	GLBX	8	Москва	133	12769906	5016721	12576820	192899	5
23	ОАО "Ханты-Мансийский банк "	1971	-	6	Ханты-Мансийск	473	12722589	323652	2987333	214723	1
24	ОАО "Банк "Петровский "	729	PETR	18	Санкт-Петербург	3395	12589085	439907	5943321	1188151	32
25	АБМ АМРО Банк АО	2594	AABM	1	Москва	175	10566709	1079184	10007563	297877	55
26	Банк ЗЕНИТ	3255	ZENT	3	Москва	456	10407230	1000661	8303786	623716	57
27	НОМОС-БАНК	2209	NMOS	1	Москва	260	8916553	1416318	8799375	161874	26
28	АКБ "Московский Индустриальный банк"	912	MIND	36	Москва	2845	8467224	938868	6145063	45861	32
29	АКБ "Ак-Барс"	2590	AKBA	20	Казань	1667	8401583	2515240	7218500	425402	37
30	ИМПЭКСБАНК (ООО)	2291	IMEX	41	Москва	1731	7963291	1015977	3631085	494875	10
31	АКБ "ЧЕЛИНДБАНК"	485	-	28	Челябинск	1392	7767092	463445	3934709	520529	23
32	ЗАО "Конверсбанк"	122	CONV	10	Москва	957	7618503	1716464	6341373	806911	25
33	ОАО "Банк "Санкт-Петербург"	436	BS PB	7	Санкт-Петербург	1503	6730121	255345	2866942	173000	15

Рисунок 52 — Исходные данные




Рисунок 53 — Обработчик «Карта Кохонена»




Рисунок 54 — Полученная карта «Кластеры»




Рисунок 55 — Банки кластера 1




Рисунок 56 — Банки кластера 5




Рисунок 57 — Банки кластера 4




Рисунок 58 — Банки кластера 3




Рисунок 59 — Банки кластера 2




Рисунок 60 — Сумма активов кластера 0




Рисунок 61 — Многомерная диаграмма




Рисунок 61 — Многомерная диаграмма «Филиалы»

Вывод: В самом богатом кластере 0 филиалы играют не самую решающую роль.




Рисунок 62 — Значимость поля «Филиалы»




Рисунок 63 — Карта Кохонена для параметра «Прибыль»



Рисунок 64 — Таблица «Профили кластеров»

Вопросы для самоконтроля

1. Что такое карта Кохонена?

— Карта Кохонена (Self-Organizing Map, SOM) — это тип искусственной нейронной сети, обучаемой без учителя, которая используется для визуализации и кластеризации многомерных данных. Её ключевая особенность — способность сохранять топологические свойства исходного пространства. Это означает, что объекты, близкие в многомерном пространстве признаков, будут расположены рядом и на самой двумерной карте. Карта представляет собой сетку (обычно прямоугольную или гексагональную) из нейронов (ячеек), каждый из которых связан с вектором весов, имеющим размерность исходных данных.

2. Для решения каких задач используются самоорганизующиеся карты Кохонена?

— Визуализация и исследование многомерных данных: Проекция сложных данных на 2D-плоскость для выявления скрытых структур, паттернов и аномалий.

Кластеризация: Автоматическое группирование объектов в кластеры. Сама карта является инструментом кластеризации, где каждая ячейка или группа соседних ячеек может представлять собой кластер.

Поиск аномалий: Объекты, которые сильно отличаются от большинства, попадают в редко задействованные или "одинокие" ячейки карты.

Понижение размерности: Сведение многомерного описания объектов к их расположению на двумерной карте.

3. В чем отличие самоорганизующихся карт Кохонена от других средств отображения кластеризации?

— Главное отличие — сохранение топологии. В таких методах, как К-средние, кластеры "изолированы" друг от друга, и их взаимное расположение не несёт смысла. В карте Кохонена соседство ячеек имеет значение: похожие кластеры расположены рядом, а различные — далеко друг от друга. Это позволяет увидеть не просто набор групп, а непрерывный "ландшафт" данных с плавными переходами между разными типами объектов.

4. Зачем производится раскраска ячеек?

— Раскраска (или заливка) ячеек производится для визуального кодирования дополнительной информации о каждом нейроне карты. Чаще всего используются два типа раскраски:

По расстоянию (U-Matrix): Ячейки раскрашиваются в зависимости от среднего расстояния между весовым вектором данного нейрона и его ближайшими соседями. Темные цвета (например, синий) означают большую схожесть (малое расстояние) и, следовательно, центр кластера. Светлые цвета (желтый, белый) означают границы между кластерами (большие расстояния между нейронами).

По значению переменной: Карту можно раскрасить в соответствии со значением одного из исходных признаков (например, "Средний чек"). Это позволяет увидеть, как конкретный параметр распределен по карте и коррелирует ли он с кластерной структурой.

5. Как определить число кластеров в обработчике Карта Кохонена?

— В Deductor число кластеров определяется после построения карты, а не до, как в методе К-средних. Процесс выглядит так:

1. Строится сама карта Кохонена.
2. Аналитик визуально изучает карту расстояний (U-Matrix), на которой видны "впадины" (плотные группы схожих ячеек) и "хребты" (границы между ними).
3. На основе этой визуальной оценки пользователь вручную задает число кластеров, которое он видит на карте. Далее система автоматически объединяет ячейки карты в это заданное количество кластеров.

6. Что такое обучение без учителя?

— Обучение без учителя — это тип машинного обучения, при котором алгоритм ищет скрытые структуры и закономерности в данных без заранее

известных правильных ответов или меток. В отличие от обучения с учителем (классификация, регрессия), где модель учит предсказывать известную целевую переменную, здесь цель — найти внутреннюю организацию данных, такую как кластеры, ассоциации или аномалии. Кластеризация, к которой относится и метод карт Кохонена, — классический пример обучения без учителя.

7. Что отображает карта Матрица расстояний?

— Карта "Матрица расстояний" (U-Matrix, Unified Distance Matrix) — это основной инструмент для визуального определения кластеров на карте Кохонена. Она отображает расстояния между соседними нейронами карты.

- Темные/холодные цвета (например, синий): обозначают малые расстояния. Это означает, что нейроны в этой области и их весовые векторы очень похожи. Такие области представляют собой ядра кластеров.
- Светлые/теплые цвета (например, желтый, красный): обозначают большие расстояния. Эти "возвышенности" или "хребты" служат границами между кластерами, показывая, где данные резко меняют свои свойства.

Таким образом, глядя на U-Matrix, аналитик буквально "видит" горный ландшафт данных, где впадины — это кластеры, а горные хребты — их границы.